



CS 2569

การเสนอเค้าโครงโครงการ

การพัฒนาโมเดลจำแนกประเภทข้อความร้องเรียนของลูกค้า

Customer Complaint Text Classification

โดย

663380590-6 นางสาวจิตรา นุช ประทุมวงศ์

663380611-4 นายภูชิต จำปาชน

อาจารย์ที่ปรึกษา : อ.ธนพล ตั้งชูพงศ์

รายงานนี้เป็นส่วนหนึ่งของการศึกษาวิชา CP354771 โครงการทางวิทยาการคอมพิวเตอร์ 1

ภาคเรียนที่ 1 ปีการศึกษา 2569

สาขาวิชาวิทยาการคอมพิวเตอร์ วิทยาลัยการคอมพิวเตอร์

มหาวิทยาลัยขอนแก่น

(กรกฎาคม 2569)

การเสนอเค้าโครงโครงการงานคอมพิวเตอร์

สาขาวิชาวิทยาการคอมพิวเตอร์ วิทยาลัยการคอมพิวเตอร์ มหาวิทยาลัยขอนแก่น

ชื่อ	นางสาวจิตรา นุช ประทุมวงศ์	รหัสประจำตัว	663380590-6
	Miss. Jittranuch Pratoomwong		
	นายภูชิต จำปาชน	รหัสประจำตัว	663380611-4
	Mr. Phuchit Champachon		

นักศึกษาระดับปริญญาตรี	หลักสูตรวิทยาศาสตรบัณฑิต สาขาวิชาวิทยาการคอมพิวเตอร์
อาจารย์ที่ปรึกษาโครงการ	อ.ธนพล ตั้งชูพงษ์
Project Advisor Lecturer	Thanaphon Tangchoopong

1. ชื่อหัวข้อโครงการ

ภาษาไทย การพัฒนาโมเดลจำแนกประเภทข้อความร้องเรียนของลูกค้า
ภาษาอังกฤษ Customer Complaint Text Classification

2. ที่มาและความสำคัญของปัญหา

ปัจจุบันธุรกิจอีคอมเมิร์ซ (E-commerce) ในประเทศไทยมีการเติบโตอย่างต่อเนื่อง สอดคล้องกับรายงานของ Statista ที่ระบุว่ามูลค่าตลาดอีคอมเมิร์ซของไทยมีแนวโน้มเพิ่มสูงขึ้นในทุกปี [1] การขยายตัวดังกล่าวส่งผลให้ปริมาณการติดต่อและข้อร้องเรียนจากลูกค้าเพิ่มสูงขึ้นตามไปด้วย [2] โดยข้อร้องเรียนเหล่านี้มีความหลากหลายและครอบคลุมหลายประเด็น เช่น การจัดส่งสินค้าผิดพลาด สินค้าชำรุด สินค้าไม่ครบจำนวน การขอใบกำกับภาษี การขอคืนเงินหรือคืนสินค้า และการติดตามสถานะการจัดส่ง เป็นต้น ซึ่งหากองค์กรต้องอาศัยพนักงาน (Human Agent) ในการอ่านและคัดแยกหมวดหมู่ข้อความด้วยตนเองทีละรายการ ย่อมก่อให้เกิดความล่าช้าในการตอบสนองปัญหา และอาจส่งผลกระทบต่อประสิทธิภาพและความพึงพอใจของลูกค้าโดยตรง

อย่างไรก็ตาม แนวทางที่ใช้ในปัจจุบันสำหรับการคัดแยกข้อความร้องเรียนแบบอัตโนมัติยังมีข้อจำกัดหลายประการ ได้แก่ (1) ระบบที่อาศัยคำสำคัญ (Keyword-based System) ซึ่งต้องอาศัยผู้เชี่ยวชาญในการกำหนดกฎ แม้จะมีความเร็วในการประมวลผลสูง แต่ขาดความยืดหยุ่นเมื่อเผชิญกับภาษาพูด คำสแลง หรือประโยคที่มีความซับซ้อนกำกวม (2) โมเดลการเรียนรู้ของเครื่องแบบดั้งเดิม (Traditional Machine Learning) เช่น Naive Bayes หรือ SVM ที่จำเป็นต้องอาศัยชุดข้อมูลสำหรับฝึกสอน (Labeled Data) ปริมาณมหาศาล อีกทั้งยังมีข้อจำกัดด้านประสิทธิภาพเมื่อนำมาประมวลผลภาษาไทย และ (3) ระบบการจัดการตั๋วปัญหา (Ticketing System) ที่แม้จะมีการจัดหมวดหมู่ที่เป็นระเบียบ แต่ก็ยังคงต้องอาศัยมนุษย์ในการคัดกรองเบื้องต้นในหลายกรณี

จากข้อจำกัดดังกล่าว โครงการนี้จึงเล็งเห็นถึงความท้าทายในการพัฒนาโมเดลจำแนกประเภทข้อความภาษาไทย เนื่องจากภาษาไทยมีทรัพยากรข้อมูลที่จำกัด ส่งผลให้โมเดลทั่วไปมีประสิทธิภาพลดลง [3] ประกอบกับการขาดแคลนชุดข้อมูลการร้องเรียนของลูกค้าภาษาไทยที่ถูกจัดหมวดหมู่ไว้อย่างสมบูรณ์ โครงการนี้จึงมุ่งศึกษาและประยุกต์ใช้โมเดลภาษาขนาดใหญ่ (Large Language Models: LLMs) ด้วยเทคนิค Zero-shot Classification ซึ่งสามารถจำแนกหมวดหมู่ข้อความได้โดยไม่ต้องใช้ชุดข้อมูลฝึกสอนจำนวนมาก และนำมาเปรียบเทียบกับโมเดลแบบดั้งเดิมที่ผ่านการฝึกสอน (Supervised Models) เพื่อค้นหาแนวทางที่มีประสิทธิภาพและเหมาะสมที่สุดสำหรับการจัดการข้อความร้องเรียนภาษาไทย

3. วัตถุประสงค์ของโครงการ

1. เพื่อพัฒนาระบบจำแนกข้อความร้องเรียนของลูกค้า
2. เพื่อศึกษาประสิทธิภาพของ Large Language Models ในการทำ Zero-shot Classification
3. เพื่อเปรียบเทียบประสิทธิภาพระหว่างโมเดล LLM แบบ Zero-shot Classification กับโมเดลที่ผ่านการฝึกจากชุดข้อมูล

4. ทฤษฎีและงานวิจัยที่เกี่ยวข้อง

4.1 ทฤษฎีที่เกี่ยวข้อง

4.1.1 การประมวลผลภาษาธรรมชาติและการตัดคำภาษาไทย (Thai Word Tokenization)

การตัดคำ (Word Tokenization) เป็นขั้นตอนสำคัญในการประมวลผลภาษาธรรมชาติ โดยเฉพาะภาษาไทยที่ไม่มีการเว้นวรรคระหว่างคำอย่างชัดเจน การตัดคำที่นิยมใช้มี 2 แนวทางหลัก ได้แก่ การตัดคำแบบอิงพจนานุกรม (Dictionary-based) เช่น อัลกอริทึม Maximal Matching ที่ใช้ในไลบรารี PyThaiNLP [4] ซึ่งให้ผลลัพธ์ที่อ่านเข้าใจง่ายแต่อาจมีปัญหาเมื่อพบคำศัพท์ใหม่ (Out-of-Vocabulary: OOV) และแนวทางการตัดคำระดับหน่วยย่อย (Subword Tokenization) เช่น SentencePiece ซึ่งใช้หลักการทางสถิติในการเรียนรู้หน่วยย่อยของคำ ทำให้สามารถจัดการกับคำศัพท์ใหม่ได้ดีกว่า ซึ่งเป็นแนวทางหลักที่นิยมใช้ร่วมกับโมเดลภาษาขนาดใหญ่ในปัจจุบัน

4.1.2 โมเดลการเรียนรู้ของเครื่องสำหรับการจำแนกประเภทข้อความ

สถาปัตยกรรม Transformer ถือเป็นรากฐานสำคัญของโมเดลที่ใช้ในโครงการนี้ โดยแบ่งเป็น 2 กลุ่มหลัก ได้แก่:

- (1) โมเดลภาษาเฉพาะภาษาไทย (Thai-centric Language Models): ได้แก่ WangchanBERTa [5] ซึ่งพัฒนามาจากสถาปัตยกรรม RoBERTa และฝึกสอนด้วยชุดข้อมูลภาษาไทยขนาดใหญ่กว่า 78.5 GB โดยใช้ SentencePiece ทำให้มีความเข้าใจบริบทภาษาไทยได้อย่างมีประสิทธิภาพ นอกจากนี้ยังมีโมเดลขนาดใหญ่อย่าง Typhoon2-7B [3] ที่ออกแบบให้รองรับการสั่งงานด้วยภาษาไทย
- (2) โมเดลภาษารองรับหลายภาษา (Multilingual Models): ได้แก่ Multilingual BERT (mBERT) และ LLM เจนเนอเรชัน เช่น GPT-4o และ Claude 3.5 Sonnet ซึ่งมีความสามารถในการแปลและทำความเข้าใจได้หลายภาษาแบบ Zero-shot

4.1.3 ตัวชี้วัดประสิทธิภาพ (Evaluation Metrics)

การประเมินประสิทธิภาพของโมเดลจำแนกประเภทข้อความ โดยเฉพาะข้อมูลที่มีความไม่สมดุล (Imbalanced Data) มักใช้ตัวชี้วัดดังนี้:

- (1) Accuracy (ความแม่นยำ): สัดส่วนที่โมเดลสามารถทำนายประเภทได้ถูกต้องจากข้อมูลทั้งหมด
- (2) Macro F1-Score: ค่าเฉลี่ยของ F1-Score จากทุกคลาส โดยให้น้ำหนักแต่ละคลาสเท่า ๆ กัน ช่วยให้เห็นประสิทธิภาพรวมได้ดีในกรณีที่บางคลาสนี้อย่างน้อย
- (3) Confusion Matrix: ตารางแสดงการเปรียบเทียบระหว่างประเภทที่โมเดลทำนายกับประเภทที่เป็นจริง ช่วยวิเคราะห์ว่าโมเดลมักสับสนระหว่างคลาสใด (Misclassification)

4.2 งานวิจัยที่เกี่ยวข้อง

4.2.1 Text Classification in the LLM Era — Where do we stand? [6]

งานวิจัยของ Vajjala และ Shimangaud [6] ได้เปรียบเทียบวิธีการจำแนกข้อความ 4 รูปแบบ ได้แก่ Zero-shot, Few-shot Fine-tuning, Synthetic Data-based Classification และ Fully Supervised Classification บนชุดข้อมูล 32 ชุด ครอบคลุม 8 ภาษา ผลการทดลองพบว่า Zero-shot ให้ผลดีในงาน Sentiment Analysis แต่สำหรับงานจำแนกประเภทอื่น Few-shot Fine-tuning และ Fully Supervised ยังให้ความแม่นยำสูงกว่า และประสิทธิภาพของ LLM แตกต่างกันไปตามภาษา งานวิจัยนี้ไม่ได้มุ่งเน้นข้อมูลร้องเรียนของลูกค้าโดยเฉพาะและไม่ได้ศึกษาการออกแบบ Prompt อย่างละเอียด แต่ให้ภาพรวมสำคัญของแนวทางที่นำมาใช้ในโครงการนี้

4.2.2 Adaptable and Reliable Text Classification using Large Language Models [7]

งานวิจัยของ Wang และคณะ [7] เปรียบเทียบประสิทธิภาพระหว่าง Machine Learning, Deep Learning และ LLM ภายในกรอบเดียวกัน โดยทดลอง 3 รูปแบบ คือ Zero-shot, Few-shot และ Fine-tuning พบว่า LLM จำแนกข้อความได้ดีแม้ไม่มีข้อมูลฝึกเพิ่มเติม และการออกแบบ Prompt มีผลต่อประสิทธิภาพอย่างชัดเจน โดยเฉพาะกับชุดข้อมูลขนาดเล็ก LLM มีความยืดหยุ่นสูงกว่าโมเดลดั้งเดิม ข้อจำกัดคือยังไม่ได้ทดลองกับข้อมูลภาษาไทย และงานจำแนกข้อความร้องเรียนของลูกค้าโดยตรง แนวคิดเรื่องคุณภาพของ Prompt จากงานวิจัยนี้จึงถูกนำมาใช้เป็นแนวทางออกแบบ Prompt ของโครงการ

4.2.3 Think Before You Classify: The Rise of Reasoning LLMs for Consumer Complaint Classification [2]

งานวิจัยของ Roumeliotis และคณะ [2] เปรียบเทียบโมเดล GPT-4o, Claude, Gemini, DeepSeek และ Reasoning LLM ในการจำแนกข้อความร้องเรียนจากฐานข้อมูล Consumer Complaint Database ด้วยวิธี Zero-shot Prompting ภายใต้อำนาจ Prompt เดียวกัน ผลการทดลองพบว่าโมเดลที่มีความสามารถด้าน Reasoning ให้ผลดีกว่า LLM ทั่วไป และ Claude มีประสิทธิภาพสูงสุด

4.2.4 DeepSeek and GPT Fall Behind: Claude Leads in Zero-Shot Consumer Complaints Classification [8]

Roumeliotis และคณะ [8] ทดสอบเปรียบเทียบ Claude, GPT, DeepSeek และ Gemini บนชุดข้อมูล Consumer Complaint Database ยืนยันว่า Claude มีประสิทธิภาพสูงสุดในการจำแนกข้อความร้องเรียนแบบ Zero-shot และคุณภาพของ Prompt ส่งผลต่อประสิทธิภาพของทุกโมเดลอย่างชัดเจน

4.2.5 Evaluating the impact of model scale and prompting strategies on corruption allegation classification using Thai-specialized Typhoon2 language models [3]

Sriphon และคณะ [3] ศึกษาผลของขนาดโมเดลและรูปแบบ Prompt (zero-shot, one-shot, two-shot) ของโมเดลภาษาไทย Typhoon2 ต่อการจำแนกข้อร้องเรียนเรื่องทุจริตที่ยื่นต่อสำนักงานคณะกรรมการป้องกันและปราบปรามการทุจริตแห่งชาติ (ป.ป.ช.) ผลการทดลองพบว่าโมเดลขนาดใหญ่กว่า (Typhoon2-7B) ร่วมกับ Prompt แบบ two-shot ให้ผลลัพธ์ที่ดีที่สุดในกลุ่ม LLM แต่โมเดล Machine Learning แบบดั้งเดิม (Random Forest, XGBoost) ยังคงให้ผลลัพธ์ที่ดีกว่าในภาพรวม

4.2.6 Ensembling Prompting Strategies for Zero-shot Hierarchical Text Classification with LLMs [9]

Xia และคณะ [9] เสนอแนวทาง Prompt Ensembling คือ การรวมผลลัพธ์จาก Prompt หลายรูปแบบ (Direct, Instruction, Reasoning) เพื่อเพิ่มความแม่นยำของการจำแนกข้อความแบบ Zero-shot โดยไม่ต้องฝึกโมเดลเพิ่มเติม ผลการทดลองพบว่าวิธีนี้ช่วยลดความผิดพลาดในข้อความที่มีความกำกวมหรือซับซ้อน ข้อจำกัดคือใช้เวลาประมวลผลเพิ่มขึ้นและยังไม่ได้ทดลองกับภาษาไทย

4.2.7 Large language models are zero-shot text classifiers [10]

Wang และคณะ [10] แสดงให้เห็นว่า LLM สามารถทำหน้าที่เป็น Zero-shot Text Classifier ได้อย่างมีประสิทธิภาพในหลายงาน เช่น Sentiment Analysis, Topic Classification และ Intent Classification โดยไม่ต้องฝึกโมเดลเพิ่มเติม แม้ Fine-tuning จะให้ผลแม่นยำกว่าในบางงาน แต่ Zero-shot มีข้อดีเปรียบด้านความสะดวกและความรวดเร็ว

5. วิธีดำเนินการวิจัย

5.1 การเก็บรวบรวมข้อมูล

รวบรวมข้อความร้องเรียนของลูกค้าจากระบบบริการลูกค้าของร้านค้าออนไลน์ (ช่องทาง Live Chat และ Inbox) ในช่วงกรอบเวลา 3 เดือน (พฤษภาคม - กรกฎาคม 2569) โดยตั้งเป้าหมายจำนวนตัวอย่างไว้ที่ 1,000 ข้อความ ที่ครอบคลุม 11 ประเภทตาม label ที่กำหนด ข้อมูลจะผ่านการคัดกรองเบื้องต้นเพื่อตัดข้อความสแปมหรือข้อความสั้นที่ไม่มีใจความสำคัญออก (เกณฑ์ความน่าเชื่อถือเบื้องต้น) และดำเนินการ anonymize ลบข้อมูลส่วนบุคคล (PDPA) เพื่อปกป้องความเป็นส่วนตัวของลูกค้า

5.2 การเตรียมข้อมูล (Data Preprocessing และ Annotation)

ทำความสะอาดข้อความ เช่น ลบ Emoji, URL, และอักขระพิเศษที่ไม่เกี่ยวข้อง จากนั้นดำเนินการ annotation โดยผู้ติด label อย่างน้อย 2 คนต่อ 1 ข้อความ และวัด Inter-annotator Agreement ด้วย Cohen's Kappa เพื่อยืนยันความสม่ำเสมอ จากนั้นแบ่งชุดข้อมูลเป็น Train 70% / Validation 15% / Test 15% โดยรักษาสัดส่วน label ให้สมดุล (Stratified Split)

5.3 การพัฒนาโมเดลจำแนกข้อความ (Supervised Baseline)

ฝึกโมเดล baseline ด้วยชุดข้อมูล Train โดยใช้ WangchanBERTa [3] ซึ่งเป็นโมเดลภาษาไทย และ mBERT (Multilingual BERT) เป็นตัวเปรียบเทียบ โดยใช้ library HuggingFace Transformers และ fine-tune ด้วย GPU บน Google Colab

5.4 การทดสอบด้วย Zero-shot Classification ผ่าน LLM

ออกแบบ Prompt ใน 3 รูปแบบ ได้แก่ Direct Prompt, Instruction Prompt และ Reasoning Prompt [9] และทดสอบกับโมเดล LLM ที่เลือกใช้ ได้แก่ Claude 3.5 Sonnet (Anthropic API), GPT-4o (OpenAI API) และ Typhoon2-7B [3] (สำหรับภาษาไทยโดยเฉพาะ) โดยส่ง prompt ผ่าน API และบันทึกผลลัพธ์บน Test set ชุดเดียวกันกับ supervised baseline

5.5 การประเมินผลและเปรียบเทียบ

วัดประสิทธิภาพด้วย Accuracy และ Macro F1-score บน Test set วิเคราะห์ Confusion Matrix รายประเภท เพื่อระบุ label ที่โมเดลจำแนกได้ยาก และเปรียบเทียบประสิทธิภาพระหว่างโมเดล supervised (WangchanBERTa, mBERT) กับ Zero-shot LLM (Claude, GPT-4o, Typhoon2) รวมถึงวิเคราะห์ผลกระทบของรูปแบบ Prompt ต่อประสิทธิภาพ

6. การวิเคราะห์และออกแบบระบบ

เนื่องจากโครงการนี้มุ่งเน้นการวิจัยและพัฒนาโมเดลปัญญาประดิษฐ์ (AI/ML Research) ระบบที่จะพัฒนาจึงอยู่ในรูปแบบของ Data Processing Pipeline สำหรับการจำแนกข้อความอัตโนมัติ โดยมีรายละเอียดการวิเคราะห์และออกแบบสถาปัตยกรรมดังนี้

6.1 ผู้ใช้งานระบบ (Actors) และสิทธิ์การใช้งาน

6.1.1 พนักงานฝ่ายบริการลูกค้า (CS Staff)

เป็นผู้ส่งต่อข้อมูลข้อความร้องเรียนดิบที่ส่งเข้ามาในแต่ละวันเข้าสู่ระบบ และรับผลลัพธ์การจำแนกประเภทเพื่อนำไปแจกจ่ายงาน (Ticket Routing) ให้แผนกที่เกี่ยวข้องต่อไป (Use case: นำเข้าข้อมูล, ดูผลลัพธ์การจำแนก)

6.1.2 ผู้พัฒนาระบบ (AI Engineer/Data Scientist)
เป็นผู้ดูแลระบบ อัปเดตชุดข้อมูล ทดสอบ prompt และบำรุงรักษาโมเดลให้มีความแม่นยำ (Use case: ปรับปรุงโมเดล, ประเมินประสิทธิภาพ)

6.2 สถาปัตยกรรมและกระบวนการทำงาน (Pipeline Architecture)
การทำงานของระบบประมวลผล (Data Flow) ถูกออกแบบเป็นไปป์ไลน์ 4 ขั้นตอนหลักดังนี้:

6.2.1 Data Ingestion (การรับข้อมูล)
ระบบรับข้อมูลข้อความร้องเรียนจากฐานข้อมูลลูกค้าในรูปแบบไฟล์ (เช่น CSV) หรือดึงข้อมูลผ่าน API จากระบบ Ticketing เดิม

6.2.2 Data Preprocessing (การเตรียมข้อมูล)
โมดูลทำความสะอาดข้อความ ลบคำหยาบ และกระบวนการ Anonymization/De-identification เพื่อปกปิดข้อมูลส่วนบุคคล (PII) ของลูกค้าก่อนส่งให้โมเดลประมวลผล

6.2.3 Inference Engine (เอนจินจำแนกข้อความ)
ข้อมูลที่พร้อมใช้งานจะถูกส่งเข้าสู่แกนหลักของระบบเพื่อทำนายประเภท

- (1) กรณีใช้ Supervised Model: ข้อความถูกส่งเข้าโมเดล WangchanBERTa ที่ผ่านการ Fine-tune และ Deploy ไว้บนเซิร์ฟเวอร์
- (2) กรณีใช้ Zero-shot LLM: ข้อความถูกประกอบเข้ากับ Prompt ที่ออกแบบไว้ และส่งไปยัง API ของ Large Language Model (เช่น Claude 3.5 Sonnet หรือ GPT-4o)

6.2.4 Post-processing & Output
ผลลัพธ์ที่ได้จากการทำนาย (Predicted Label) จะถูกแนบกลับไปกับข้อความต้นฉบับ และส่งออกเป็นรายงานสรุป (Report) หรือส่งคืนกลับไปยังระบบ Ticketing เพื่อให้เจ้าหน้าที่ CS นำไปดำเนินการแก้ไขปัญหาให้ลูกค้าต่อไป

7. ขอบเขตของโครงการ

7.1 ข้อมูล
ตารางที่ 1 ตารางข้อมูล Label

Label	ชื่อไทย	ตัวอย่างข้อความจากลูกค้า
Wrong Item	ได้รับสินค้าผิด	สั่งเสื้อสีดำแต่ได้รับสีขาวมาแทนคะ
Damaged Item	สินค้าชำรุด	กล่องมาถึงบวมและของข้างในแตกคะ
Missing Item	ของไม่ครบ	สั่งไป 3 ชิ้น แต่ได้รับมาแค่ 2 ชิ้นครับ
Invoice Request	ขอใบกำกับภาษี	รบกวนขอใบกำกับภาษีเต็มรูปแบบสำหรับออเดอร์นี้ด้วยคะ
Return	ขอคืนสินค้า	อยากคืนสินค้าเพราะไม่ตรงกับที่สั่ง ต้องทำอย่างไรบ้างคะ
Exchange	ขอเปลี่ยนสินค้า	อยากเปลี่ยนไซส์จาก M เป็น L ได้ไหมคะ
Delivery Delay	ส่งช้า	สั่งไปตั้งแต่อำทิตย์ที่แล้วแต่ของยังไม่มาเลยครับ
Address Change	เปลี่ยนที่อยู่	ขอเปลี่ยนที่อยู่จัดส่งเป็นที่ทำงานแทนได้ไหมคะ
Refund	ขอคืนเงิน	อยากขอเงินคืนเพราะยกเลิกออเดอร์แล้วคะ
Excess Item	ได้รับสินค้าเกิน	ได้รับสินค้าเกินจากที่สั่งไป 1 ชิ้นครับ
Shipping Status Inquiry	สอบถามสถานะขนส่ง	ติดตามสถานะขนส่งยังงัยคะ / ออเดอร์จะมาถึงวันไหนคะ / ติดต่อคนขับส่งของไม่ได้เลยคะ

7.2 จริยธรรมข้อมูล (Data Ethics)

เนื่องจากโครงการนี้ใช้ข้อมูลจริงจากลูกค้าร้านค้าออนไลน์ จึงกำหนดแนวทางปฏิบัติด้านจริยธรรมข้อมูลอย่างเคร่งครัด ดังนี้:

7.2.1 การลบข้อมูลระบุตัวตน (Anonymization/De-identification)

ข้อมูลส่วนบุคคล (PII) เช่น ชื่อ เบอร์โทรศัพท์ ที่อยู่ และหมายเลขคำสั่งซื้อ จะถูกลบหรือเข้ารหัสก่อนนำเข้าสู่กระบวนการวิเคราะห์ เพื่อให้สอดคล้องกับ พ.ร.บ.คุ้มครองข้อมูลส่วนบุคคล (PDPA)

7.2.2 การเก็บรักษาและสิทธิการเข้าถึง

ข้อมูลจะถูกจัดเก็บในสภาพแวดล้อมที่ปลอดภัย (Secure Environment) จำกัดสิทธิ์การเข้าถึงเฉพาะผู้ดำเนินงานวิจัย และจะถูกลบทิ้งอย่างถาวรเมื่อเสร็จสิ้นโครงการ

7.2.3 ข้อตกลงการใช้งาน

ข้อมูลถูกนำมาใช้เพื่อวัตถุประสงค์ในการศึกษาวิจัยและพัฒนาระบบอัตโนมัติภายในเท่านั้น จะไม่มีการนำข้อมูลดิบไปแสวงหาผลกำไรหรือเผยแพร่สู่สาธารณะโดยเด็ดขาด

7.3 โมเดลเปรียบเทียบ

7.3.1 โมเดล Large Language Model (Zero-shot)

- (1) Typhoon2-7B: เลือกใช้เนื่องจากเป็นโมเดลที่พัฒนาและฝึกสอนสำหรับภาษาไทยโดยเฉพาะ (Thai-centric) จึงคาดว่าจะมีความเข้าใจบริบทภาษาพูดและคำสแลงไทยได้ดี
- (2) GPT-4o: เลือกใช้เพื่อเป็นตัวแทนของโมเดลเชิงพาณิชย์ระดับ State-of-the-Art ที่มีประสิทธิภาพสูงในการวิเคราะห์และจัดหมวดหมู่ข้อความ
- (3) Claude 3.5 Sonnet: เลือกใช้เนื่องจากมีความโดดเด่นด้านการปฏิบัติตามคำสั่ง (Instruction Following) ซึ่งเหมาะสมกับการใช้ Prompt ที่มีความซับซ้อน

7.3.2 โมเดล Supervised Baseline

- (1) WangchanBERTa: เลือกใช้เป็นตัวแทนของโมเดล Pre-trained ภาษาไทยแบบดั้งเดิมที่เหมาะสมสำหรับงาน text classification
- (2) mBERT: เลือกใช้เป็นตัวแทนของโมเดล Multilingual เพื่อเปรียบเทียบประสิทธิภาพกับโมเดลภาษาไทยเฉพาะทาง

7.4 ระเบียบวิธีทดสอบและตัวชี้วัด (Testing Protocol and Metrics)

7.4.1 ระเบียบวิธีทดสอบ (Testing Protocol)

ข้อมูลจะถูกแบ่งด้วยเทคนิค Stratified Split เป็นสัดส่วน Train 70%, Validation 15%, และ Test 15% เพื่อรักษาการกระจายตัวของข้อมูลที่ไม่สมดุล (Imbalanced data) ในทุกชุด การประเมินประสิทธิภาพจะวัดจากชุด Test set โดยใช้ WangchanBERTa เป็น Baseline สำหรับเปรียบเทียบกับ LLM ในการประเมินฝั่ง Supervised Model จะมีการรันแบบสุ่มซ้ำอย่างน้อย 3 รอบ และรายงานผลเป็นค่าเฉลี่ยเพื่อความน่าเชื่อถือเชิงสถิติ

7.4.2 ตัวชี้วัด (Metrics)

- (1) Accuracy: วัดความแม่นยำรวมของการจำแนกประเภทข้อความทั้งหมด
- (2) Macro F1-score: ใช้เป็นตัวชี้วัดหลักเพื่อรับมือกับปัญหาคลาสไม่สมดุล เนื่องจากพิจารณาความสำคัญของทุกประเภทข้อความเท่าเทียมกัน
- (3) Per-class F1-score: เพื่อวิเคราะห์ประสิทธิภาพเชิงลึกว่าโมเดลทำได้ดีหรือด้อยในประเภทคำร้องเรียนใดเป็นพิเศษ

- (4) Confusion Matrix: ใช้สรุปและแสดงจุดที่โมเดลมักทำนายผิดพลาดข้ามคลาส (Misclassification) ซึ่งช่วยให้เข้าใจความกำกวมของคำร้องเรียน

8. สถานที่ทำวิจัย

สาขาวิชาวิทยาการคอมพิวเตอร์ วิทยาลัยการคอมพิวเตอร์ มหาวิทยาลัยขอนแก่น หรืออื่น ๆ

9. ผลที่คาดว่าจะได้รับ

1. ชุดข้อมูลข้อความติดต่อของลูกค้าที่มีการติด label พร้อมสำหรับใช้งานและต่อยอด
2. โมเดลต้นแบบสำหรับจำแนกประเภทข้อความร้องเรียนของลูกค้าโดยใช้ Zero-shot Text Classification
3. ผลการเปรียบเทียบประสิทธิภาพระหว่างโมเดล LLM

10. แผนการดำเนินงาน

ตารางที่ 2 แผนการดำเนินงาน

การดำเนินงาน	ปี 2569									
	1	2	3	4	5	6	7	8	9	10
ศึกษางานวิจัยที่เกี่ยวข้อง										
เก็บรวบรวมและเตรียมข้อมูล										
ออกแบบและพัฒนาระบบ										
ทดสอบด้วย Zero-shot Classification ผ่าน LLM										
ประเมินผลและเปรียบเทียบโมเดล										
สรุปผลและจัดทำรายงานฉบับสมบูรณ์										

11. งบประมาณ

หมวดวัสดุอุปกรณ์

- (1) ค่าวัสดุสำนักงาน (กระดาษ ปากกา ฯลฯ)
- (2) ค่าวัสดุคอมพิวเตอร์/สื่อบันทึก (แฟลชไดรฟ์ ฯลฯ)

หมวดค่าใช้สอย

- (1) ค่าถ่ายเอกสาร
- (2) ค่าจัดรูปเล่ม

หมวดค่าใช้จ่ายอื่น ๆ

- (1) ค่าเดินทาง/ประสานงานเก็บข้อมูล
- (2) ค่าตอบแทนผู้ทดสอบ (User Study ขนาดเล็ก)

เอกสารอ้างอิง

- [1] Statista Research Department, “E-commerce in thailand - statistics & facts,” 2024.
- [2] K. I. Roumeliotis *et al.*, “Think before you classify: The rise of reasoning LLMs for consumer complaint classification,” *arXiv preprint*, 2025.
- [3] T. Sriphon *et al.*, “Evaluating the impact of model scale and prompting strategies on corruption allegation classification using Thai-specialized Typhoon2 language models,” *arXiv preprint*, 2025.
- [4] W. Phatthiyaphaibun, K. Chaovavanich, C. Polpanumas, A. Suriyawongkul, L. Lowphansirikul, P. Chormai, P. Limkonchotiwat, T. Suntornitip, and C. Udomcharoenchaikit, “Pythainlp: Thai natural language processing in python,” in *Proceedings of the 3rd Workshop for Natural Language Processing Open Source Software (NLP-OSS 2023)*, pp. 25–36, 2023.
- [5] L. Lowphansirikul, C. Polpanumas, N. Jantrakulchai, and S. Nutanong, “Wangchanberta: Pretraining transformer-based thai language models,” *arXiv preprint arXiv:2101.09635*, 2021.
- [6] S. Vajjala and S. Shimangaud, “Text classification in the LLM era: Where do we stand?,” *arXiv preprint arXiv:2405.01240*, 2024.
- [7] G. Wang *et al.*, “Adaptable and reliable text classification using large language models,” *arXiv preprint*, 2023.
- [8] K. I. Roumeliotis *et al.*, “DeepSeek and GPT fall behind: Claude leads in zero-shot consumer complaints classification,” *arXiv preprint*, 2025.
- [9] Y. Xia *et al.*, “Ensembling prompting strategies for zero-shot hierarchical text classification with LLMs,” *arXiv preprint*, 2024.
- [10] Z. Wang *et al.*, “Large language models are zero-shot text classifiers,” *arXiv preprint arXiv:2312.01044*, 2023.